


CREDIT SCORE ANALYSIS

**Memaksimalkan Persetujuan Pinjaman
Melalui Prediksi Risiko**

START SLIDE



BACKGROUND PROBLEMS

Bank menghadapi dilema manajemen risiko yang klasik:

- **Risiko 1: Kerugian Kredit (Credit Loss)**
Menyetujui pinjaman untuk nasabah yang akhirnya Gagal Bayar. Ini menyebabkan kerugian finansial langsung.
- **Risiko 2: Kehilangan Peluang (Opportunity Loss)**
Menolak pinjaman untuk nasabah yang sebenarnya Mampu Bayar. Ini menyebabkan kehilangan pendapatan (revenue) dan calon pelanggan.

GOALS



Membangun sistem credit scoring (penilaian kredit) berbasis data yang akurat untuk mengoptimalkan keputusan persetujuan pinjaman.



Menerapkan model Klasifikasi Biner (Machine Learning) untuk memprediksi probabilitas (skor risiko) apakah seorang nasabah akan Gagal Bayar (1) atau Lunas (0).





DATA OVERVIEW

JUMLAH DATA: 307,511 aplikasi pinjaman (application_train.csv).

STRUKTUR DATASET: Terdiri dari 10 file terpisah yang saling terhubung.


- Dataset utama : *application_train.csv* (122 fitur, berisi TARGET).
- Data Pendukung Utama:
 - *bureau.csv*: Riwayat kredit eksternal (1.7jt baris).
 - *previous_application.csv*: Riwayat kredit internal (1.6jt baris).

Tantangan utama :

- Imbalanced Data: Proporsi Gagal Bayar (Default) hanya 8% (vs 92% Lunas).
- Missing Values: Banyak fitur di data utama memiliki missing data tinggi (40-70%).
- Feature Engineering: Tantangan terbesar adalah agregasi 10 file menjadi satu set fitur "kaya" (kaya informasi).
- High Dimensionality (Dimensi Tinggi): Setelah Preprocessing (misal: One-Hot Encoding), jumlah fitur "meledak" menjadi 220+.

e^x	e^{-x}	$\sinh x$	$\cosh x$	$\tanh x$
1.0000	1.0000	.00000	1.0000	.00000
1.1052	.90484	.10017	1.0050	.09967
1.2214	.81873	.20134	1.0201	.19738
1.3499	.74082	.30452	1.0453	.29131
1.4918	.67032	.41075	1.0811	.37995
		.52110	1.1276	.46212
		.63665	1.1855	.53705
		.75858	1.2552	.60437
			1.3374	.66404
			1.4331	.71630
		1.1752		.76159
		1.3356		.80050
		1.5095		.83365
		1.6984		.86172
		1.9043		.88535
		2.1293	2.352	.90515
		2.3756	2.577	.92167
		2.6456	2.828	.93541
		2.9422	3.107	.94681
		3.2682	3.41	.95624
		3.6269	3.7	.96403
		4.0219		.97045
		4.4571		.97574
		4.9370		.98010
			5.5569	.98367
			6.1323	.98661
			6.7690	.98903
			7.4735	.99101
			8.2527	.99263
			9.1146	.99396
		10.018	10.068	.99505
		11.076	11.122	.99595
		12.246	12.287	.99668
		13.538	13.575	.99728
		14.965	14.999	.99777
		16.543	16.573	.99818
		18.285	18.313	.99851
		20.211	20.236	.99878
		22.339	22.362	.99900
		24.691	24.711	.99918

PROJECT WORKFLOW



Data Cleaning & Feature Engineering

Mengintegrasikan data dari berbagai sumber, memperbaiki kualitas data (missing value, anomaly), dan membentuk fitur



EDA & Visualization

Menganalisis karakteristik data dan mengidentifikasi insight awal menggunakan grafik, korelasi, dan distribusi variabel.




Modeling & Selection

Membangun dan membandingkan beberapa model prediktif — Logistic Regression, LightGBM, dan Random Forest — untuk memilih model dengan performa terbaik.




Tuning Model

Melakukan hyperparameter tuning dengan Grid Search untuk memperoleh kombinasi parameter terbaik pada setiap model.



Kuadran Risiko vs Volume Aplikasi (berdasarkan Tipe Pendapatan)



INSIGHT

Risiko Ekstrem

Segmen Unemployed (Pengangguran) dan Maternity leave (Cuti Melahirkan) memiliki risiko gagal bayar 4-5x lipat di atas rata-rata (35% vs 8%).

Portfolio Aman

Tidak ada segmen pelanggan utama (High Volume) yang berada di kuadran High Risk. Segmen inti seperti Working (90% disetujui) dan Commercial Associate (93% disetujui) terbukti aman dan bervolume tinggi.

RECOMMENDATION

Perketat underwriting untuk segmen berisiko tinggi dan optimalkan layanan bagi segmen inti Working yang berisiko rendah namun berkontribusi besar pada bisnis.


INSIGHT

Danger Zone

Risiko gagal bayar naik secara drastis seiring dengan naiknya rasio, dan mencapai puncaknya (9.20%) pada nasabah yang meminjam 3-4x lipat dari pendapatan tahunan mereka.

RECOMMENDATION

Diperlukan untuk menerapkan kebijakan underwriting baru dengan menetapkan batas atas rasio beban kredit. Aplikasi dengan rasio di atas ambang batas (misalnya >3.0) perlu ditandai otomatis untuk ditinjau secara manual oleh analis kredit senior.



FINAL MODEL METHODOLOGY

FEATURE ENGINEERING & SELECTION

- Fitur yang lebih informatif dikonstruksi melalui agregasi dan penggabungan data bureau.csv (riwayat kredit eksternal) serta previous_application.csv (riwayat pinjaman internal).
- Dari lebih dari 221 fitur awal, analisis feature_importance_ menyaring Top 50 fitur paling berpengaruh — mengeliminasi sekitar 77% noise. Fitur kunci mencakup AMT_CREDIT, EXT_SOURCE_3, AGE, CREDIT_INCOME_RATIO, BIRO_ACTIVE_COUNT, dan PREV_REFUSED_COUNT.


PREPROCESSING

Model final dibangun di atas pipeline ColumnTransformer yang otomatis:


1. **Imputasi:** Mengisi NaN (menggunakan Median untuk angka & Modus untuk teks).
2. **Scaling:** Menggunakan RobustScaler (untuk "kebal" terhadap outlier pendapatan).
3. **Encoding:** Menggunakan OneHotEncoder (untuk mengubah semua fitur teks).

ALGORITMA FINAL

LightGBM Classifier (LGBM) dipilih sebagai algoritma final karena performa terbaiknya (mengalahkan Logistic Regression & Random Forest).



MODEL FINAL PERFORMANCE



Hyperparameter Tuning


- Model Top 50 fitur disempurnakan menggunakan GridSearchCV (Validasi Silang 3-lapis) untuk mencari "setelan" optimal.
- Setelan Terbaik Ditemukan:
 - **learning_rate**: 0.05 (Belajar lebih "hati-hati" untuk anti-overfit)
 - **n_estimators**: 300 (Jumlah "pohon" ditambah)
 - **max_depth**: 20



Performance

- **AUC-ROC = 0.7529**
- Interpretasi: Ini adalah skor Cross-Validation (CV) yang sangat stabil dan jujur. Ini membuktikan model final kita 75% lebih baik daripada tebakan acak (AUC 0.5) dalam memisahkan nasabah yang akan gagal bayar dari nasabah yang akan lunas.

BUSINESS IMPACT



Mengurangi Kerugian Kredit (Credit Loss Reduction):

Model final mampu mengidentifikasi 68% calon gagal bayar (Recall), memungkinkan perusahaan menolak aplikasi berisiko tinggi lebih awal, sehingga menekan potensi kerugian finansial secara signifikan.



Meningkatkan Pendapatan (Revenue Growth)

Model memberikan insight berbasis data untuk memperluas persetujuan di segmen PNS & Pensiunan — kelompok berisiko rendah namun belum tergarap — membuka sumber pendapatan baru dari pasar berkualitas tinggi.



Efisiensi Operasional (Operational Efficiency)

Dengan hanya menggunakan Top 50 fitur utama, model menjadi 77% lebih ringan, lebih cepat dilatih dan di-deploy, serta lebih mudah dijelaskan kepada regulator dan stakeholder bisnis.

Thank you

REFERENCES

Dataset	Data Home Credit (Virtual Internship Project)
Tools	Python (Scikit-learn, LightGBM, Imb-learn, Pandas)
GitHub	https://github.com/ariellaacahyani/home_credit_default_prediction
Video Link	https://drive.google.com/drive/folders/1V5O70ThmOuSs0pwNrKqAkgNKL_NEmV-6?usp=sharing

CONTACT ME

E-mail	ariellacahyani@gmail.com
Social Media	@ariellastch
LinkedIn	linkedin.com/in/ariella-asti-cahyani
Address	Tangerang, Indonesia

bit.ly/portfolio_ariella